Análise de Dados da Aviação Brasileira com Python

Inspeção, qualidade e análise exploratória dos dados operacionais de voos — 2025

1. Visão geral do projeto

Este projeto tem como objetivo analisar dados operacionais da aviação brasileira utilizando Python, com foco na avaliação da qualidade dos dados e na identificação de padrões relacionados às operações aéreas.

A proposta é desenvolver um fluxo de análise estruturado, desde a obtenção e consolidação dos dados até sua validação, preparação e exploração. O projeto busca transformar registros operacionais em informações confiáveis que possam apoiar investigações sobre atrasos, cancelamentos, pontualidade e características das operações aéreas.

O desenvolvimento prioriza a rastreabilidade das transformações, a documentação das decisões de tratamento e a interpretação criteriosa dos resultados. Dessa forma, procura-se evitar conclusões que não sejam sustentadas pelos dados disponíveis.

Fonte dos dados: Agência Nacional de Aviação Civil (ANAC), base de dados VRA — Voos Regulares Ativos, referente ao ano de 2025.

Tecnologias utilizadas: Python, pandas e Plotly.

2. Objetivos

- Consolidar os arquivos mensais de dados operacionais referentes a 2025.
- Investigar a estrutura, os tipos de dados e a completude das informações.
- Identificar inconsistências, duplicidades e valores que necessitam de validação.
- Preparar os dados para análises de atrasos, cancelamentos e características das operações.
- Investigar a distribuição temporal dos voos e os padrões de pontualidade.
- Documentar os achados e as decisões de tratamento para garantir transparência e confiabilidade.
- Desenvolver visualizações que facilitem a interpretação dos resultados e a comunicação dos principais achados.

Etapa 1 — Carregamento e consolidação dos dados

Inicialmente, foram carregados os 12 arquivos mensais disponibilizados pela ANAC, referentes ao período de janeiro a dezembro de 2025.

Após a consolidação, foi obtida uma base única contendo:

Indicador	Resultado
Arquivos mensais	12
Registros originais	1.005.807
Variáveis originais	21
Período de referência	Janeiro a dezembro de 2025

Além da unificação dos arquivos, foi realizada uma verificação estrutural para avaliar a compatibilidade das colunas e da organização dos dados entre os meses.

Resultado

Os 12 arquivos apresentaram estruturas compatíveis, permitindo sua consolidação em uma única base sem a necessidade de ajustes estruturais nas colunas.

A base consolidada passou a ser utilizada como referência para as etapas de inspeção, avaliação da qualidade e tratamento dos dados.

Etapa 2 — Inspeção dos dados

Após a consolidação, foi realizada uma inspeção inicial para compreender a estrutura da base, identificar valores ausentes, verificar padrões de preenchimento e investigar possíveis inconsistências antes da avaliação detalhada da qualidade dos dados.

Nesta etapa, os registros não foram alterados nem removidos. As verificações tiveram caráter diagnóstico e serviram para orientar as etapas seguintes.

2.1 Estrutura e tipagem

Foram avaliadas as dimensões da base, as colunas disponíveis, os tipos de dados e a necessidade de conversão de variáveis.

A maior parte das colunas foi carregada como texto, incluindo os campos de datas e horários. A coluna **`Número de Assentos`** foi identificada como numérica, enquanto **`Justificativa`** foi interpretada como numérica devido à ausência de valores preenchidos.

Os campos temporais foram avaliados quanto à possibilidade de conversão para tipos apropriados, permitindo sua utilização em cálculos e comparações posteriores.

2.2 Avaliação de valores ausentes

A inspeção de completude identificou valores ausentes em algumas variáveis relevantes para a análise operacional.

Variável	Registros ausentes	Percentual ausente
Situação Partida	55.914	5,56%
Situação Chegada	55.914	5,56%
Partida Prevista	28.198	2,80%
Chegada Prevista	28.198	2,80%
Partida Real	27.716	2,76%
Chegada Real	27.716	2,76%
Código Tipo Linha	463	0,05%
Codeshare	560.346	55,71%
Justificativa	1.005.807	100,00%

Os resultados indicaram que as ausências nos horários previstos de partida e chegada ocorrem simultaneamente em 28.198 registros. Esses casos precisam ser considerados na construção dos indicadores que dependem da comparação entre horários previstos e realizados.

Também foram identificados valores ausentes nos horários reais. A análise cruzada com a situação dos voos demonstrou que os 27.716 registros sem horários reais de partida e chegada correspondem a voos cancelados.

A coluna **`Codeshare`** apresentou aproximadamente 55,71% de valores ausentes. Já a **`Justificativa`** não possuía nenhum valor preenchido. Como essas variáveis não fazem parte do escopo analítico principal, não serão utilizadas nos indicadores centrais. A exclusão de **`Justificativa`** será documentada na etapa de tratamento, enquanto **`Codeshare`** será mantida sem preenchimento automático.

2.3 Verificação de duplicidades

Foi realizada uma verificação de duplicidades exatas considerando todas as colunas da base.

O resultado identificou:

- 4 registros envolvidos em duplicidades;
- 2 pares de registros idênticos;
- 2 cópias excedentes.

Os registros pertencem à Qatar Airways (QTR), ao voo 8172, com origem no aeroporto SBGR e destino no aeroporto SKBO.

A análise dos registros indicou duas ocorrências distintas de duplicação, associadas a datas diferentes: 7 e 14 de dezembro de 2025.

Portanto, não se trata de quatro registros de um único evento duplicado, mas de duas ocorrências em que cada registro possui uma cópia exatamente igual.

Resultado

As cópias excedentes foram documentadas para avaliação na etapa de qualidade. Nenhum registro foi removido durante a inspeção inicial.

2.4 Cobertura temporal

A análise da referência temporal identificou registros distribuídos ao longo dos 12 meses de 2025.

O período identificado foi:

- **Data mínima:** 01/01/2025.
- **Data máxima:** 31/12/2025.

A conversão da referência temporal não apresentou falhas.

A presença de registros nos 12 meses indica cobertura anual da base. Essa verificação, isoladamente, não garante que todos os dias ou todas as operações tenham sido registrados.

2.5 Validação dos formatos de datas e horários

Foram inspecionados os seguintes campos:

- Partida Prevista;
- Partida Real;
- Chegada Prevista;

- Chegada Real.

Os resultados demonstraram que todos os valores não ausentes puderam ser interpretados no formato temporal esperado, sem falhas de conversão nos valores disponíveis.

Essa verificação indica consistência de formato, mas não substitui as validações de conteúdo e das regras operacionais realizadas na etapa de qualidade.

2.6 Consistência operacional e cronológica

Foram realizadas verificações cruzadas entre a situação dos voos e o preenchimento dos horários.

A análise identificou que:

- Não foram encontrados voos realizados sem horários reais de partida e chegada.
- Não foram encontrados voos cancelados com horários reais de partida ou chegada preenchidos.
- Não foram identificados casos de chegada real anterior à partida real.
- Não foram identificados casos de chegada prevista anteriormente à partida prevista.

Esses resultados indicam consistência entre as variáveis nas regras verificadas, sem representar uma validação completa de todas as condições possíveis das operações aéreas.

2.7 Perfil operacional dos voos

A distribuição da situação dos voos na base original foi:

Situação	Registros	Participação
Realizado	978.091	97,24%
Cancelado	27.716	2,76%
Total	**1.005.807**	**100,00%**

Esses percentuais representam a distribuição dos registros presentes na base analisada e não devem ser interpretados automaticamente como taxas oficiais de desempenho de toda a aviação brasileira.

Na análise dos campos de situação de partida e chegada, as categorias mais frequentes incluíram antecipações e operações pontuais, indicando a relevância desses campos para a futura investigação da pontualidade.

2.8 Classificação dos tipos de linha

A variável `Código Tipo Linha` foi preservada por seu potencial analítico na classificação das operações.

Código	Categoria	Registros	Participação na base
N	Nacional	804.861	80,02%
I	Internacional	163.796	16,29%
G	Geral	21.438	2,13%
C	Cargueiro	15.249	1,52%
Ausente	Não classificado	463	0,05%

Os resultados demonstram predominância de registros classificados como nacionais, seguidos pelos internacionais.

A variável será mantida nas próximas etapas para permitir comparações entre categorias de operação. A interpretação dos códigos considera as categorias de referência utilizadas na análise.

2.9 Aeroportos

A inspeção identificou 385 códigos ICAO distintos considerando os aeroportos de origem e destino, sem valores ausentes nesses campos.

Entre os aeroportos com maior volume operacional identificados na análise estão:

- SBGR — Guarulhos;
- SBSP — Congonhas;
- SBKP — Viracopos;
- SBGL — Galeão;
- SBBR — Brasília.

2.10 Rotas aéreas

Foram identificadas 3.192 combinações distintas de origem e destino.

A identificação das rotas permite investigar a distribuição das operações entre aeroportos e comparar o comportamento operacional de diferentes trajetos.

As rotas de maior frequência poderão ser utilizadas nas próximas análises, considerando as validações necessárias para as combinações identificadas.

2.11 Registros com origem igual ao destino

Foi realizada uma investigação inicial dos registros em que o aeroporto de origem coincide com o aeroporto de destino.

Resultados:

- Registros identificados: 4.043.
- Participação aproximada: 0,40% da base original.

A presença desses registros não permite concluir, isoladamente, que existam erros. Eles precisam ser investigados considerando variáveis como empresa aérea, modelo da aeronave, tipo de linha e horários, para compreender a natureza dessas operações antes de qualquer exclusão.

2.12 Capacidade das aeronaves

A análise da variável **`Número de Assentos`** identificou:

Indicador	Resultado
Média aproximada	166 assentos
Mediana	180 assentos
Valor máximo	515 assentos
Registros com zero assentos	46.700

A presença de valores iguais a zero exige investigação antes de qualquer tratamento. Esses registros podem estar relacionados a diferentes tipos de operação ou a situações que precisam ser validadas.

Na etapa de qualidade, os casos serão avaliados por modelo de aeronave, empresa aérea e tipo de linha, evitando classificar automaticamente esses valores como erros.

2.13 Principais conclusões da inspeção

A inspeção inicial permitiu compreender a estrutura da base, verificar sua cobertura temporal e identificar padrões relevantes para a preparação dos dados.

Os resultados indicam que os arquivos mensais apresentam estrutura compatível e que algumas relações entre a situação dos voos e o preenchimento dos horários são coerentes com o comportamento esperado.

Entretanto, a inspeção também identificou pontos que exigem investigação antes de decisões definitivas de tratamento:

- Duas cópias excedentes de registros duplicados exatos.
- Ausência simultânea dos horários previstos de partida e chegada em aproximadamente 2,80% dos registros.
- Registros com número de assentos igual a zero.
- Operações em que os aeroportos de origem e destino são iguais.
- Pequena quantidade de registros sem classificação de tipo de linha.
- Divergências entre diferenças de horário calculadas e classificações operacionais originais.

Esses pontos foram considerados na etapa seguinte, dedicada à avaliação estruturada da qualidade dos dados.

Etapa 3 — Qualidade dos dados

Após a inspeção inicial, foi realizada uma etapa estruturada de avaliação da qualidade dos dados operacionais de voos de 2025. O objetivo foi verificar a completude, a unicidade, a validade e a consistência das informações, identificando possíveis problemas que poderiam afetar a confiabilidade das análises posteriores.

As verificações foram desenvolvidas em Python, com foco na identificação e documentação dos achados. Nesta etapa, a base original foi preservada: nenhuma linha foi removida, nenhum valor foi imputado e nenhuma categoria original foi alterada.

3.1 Completude dos dados

A análise de completude confirmou os padrões de ausência identificados durante a inspeção inicial.

Variável	Registros ausentes	Percentual ausente
Situação Partida	55.914	5,56%
Situação Chegada	55.914	5,56%
Partida Prevista	28.198	2,80%
Chegada Prevista	28.198	2,80%
Partida Real	27.716	2,76%

Chegada Real	27.716	2,76%
Código Tipo Linha	463	0,05%

Foi confirmada a ausência simultânea dos horários previstos de partida e chegada em 28.198 registros. Não foram identificados casos em que apenas um desses dois horários estivesse ausente.

As ausências nos horários reais foram associadas aos voos cancelados. Os 27.716 registros classificados como cancelados não possuem horários reais de partida ou chegada preenchidos, enquanto os voos realizados apresentam ambos os horários reais.

A ausência das classificações de partida e chegada totaliza 55.914 registros em cada coluna. Esse total não corresponde somente aos cancelamentos: além dos 27.716 voos cancelados, há 28.198 registros de voos realizados sem classificação de partida e chegada.

Conclusão

As ausências foram quantificadas e relacionadas às características operacionais dos registros. Não foi realizada imputação, pois o preenchimento automático poderia introduzir informações não sustentadas pelos dados.

3.2 Unicidade dos registros

A verificação de duplicidades exatas, considerando todas as colunas da base, identificou:

Indicador	Resultado
Registros analisados	1.005.807
Registros envolvidos em duplicidades	4
Pares de registros idênticos	2
Cópias excedentes	2

Os registros pertencem à Qatar Airways (QTR), voo 8172, na rota entre SBGR e SKBO, com ocorrências em 7 e 14 de dezembro de 2025.

A análise confirmou duas ocorrências distintas de duplicação, cada uma envolvendo um par de registros idênticos.

3.3 Validade dos horários

Foram avaliados os campos Partida Prevista, Partida Real, Chegada Prevista e Chegada Real, considerando os valores ausentes e a possibilidade de conversão para o formato temporal esperado.

Entre os valores preenchidos, não foram identificados horários inválidos ou falhas de conversão.

Essa verificação demonstra consistência de formato nos valores disponíveis. Ela não garante, por si só, que todos os horários estejam corretos em relação à operação real, mas fornece uma base para os cálculos temporais posteriores.

3.4 Validade das categorias

Foram avaliadas as categorias das variáveis Situação Voo, Situação Partida, Situação Chegada e Código Tipo Linha.

Na variável **`Situação Voo`**, foram encontrados 978.091 registros classificados como REALIZADO e 27.716 como CANCELADO. Não foram identificados valores ausentes ou categorias preenchidas fora dos valores esperados.

Nas variáveis **`Situação Partida`** e **`Situação Chegada`**, foram encontradas seis categorias preenchidas: antecipado, pontual e quatro faixas de atraso. Ambas apresentaram 55.914 registros sem classificação.

Para **`Código Tipo Linha`**, foi utilizada a seguinte classificação de referência:

Código	Categoria	Registros	Participação na base
N	Nacional	804.861	80,02%
I	Internacional	163.796	16,29%
G	Geral	21.438	2,13%
C	Cargueiro	15.249	1,52%
Ausente	Não classificado	463	0,05%

Todos os códigos preenchidos corresponderam às categorias de referência utilizadas na análise. Não foram encontrados códigos preenchidos não reconhecidos.

3.5 Consistência operacional e cronológica

Foram realizadas verificações cruzadas entre a situação dos voos e os horários registrados, além de comparações cronológicas entre partidas e chegadas.

Os principais resultados foram:

- Nenhum voo realizado sem partida real preenchida e válida.
- Nenhum voo realizado sem chegada real preenchida e válida.
- Nenhum voo cancelado com partida ou chegada real preenchida e válida.
- Nenhum caso de chegada real anterior à partida real.
- Nenhum caso de chegada prevista anterior à partida prevista.

A consistência cronológica foi avaliada em 978.091 registros com ambos os horários reais disponíveis e em 977.609 registros com ambos os horários previstos disponíveis, conforme a base e os critérios utilizados nessa verificação.

3.6 Qualidade do número de assentos

A variável **`Número de Assentos`** foi avaliada quanto a valores ausentes, não numéricos, negativos, fracionários e iguais a zero.

Verificação	Resultado
Registros com assentos positivos	959.107
Registros com zero assentos	46.700
Registros com assentos negativos	0
Valores ausentes	0
Valores preenchidos não numéricos	0
Valores fracionários	0

Os registros com zero assentos representam aproximadamente 4,64% da base original. A distribuição por modelo de equipamento e tipo de linha indicou concentração desses valores em determinadas categorias operacionais, incluindo operações cargueiras.

Esses resultados exigem interpretação contextual. Um valor igual a zero não deve ser considerado automaticamente um erro, pois sua validade depende do significado do campo e das características da operação registrada.

3.7 Consistência da identificação das empresas aéreas

Foram verificadas as associações entre os códigos e os nomes das empresas aéreas, buscando identificar códigos associados a múltiplos nomes ou nomes associados a múltiplos códigos.

Não foram encontradas inconsistências nesses relacionamentos. Também não foram identificados registros com código e nome simultaneamente ausentes, nem casos em que apenas um desses campos estivesse ausente.

Conclusão

Não foram identificados problemas de consistência na identificação das empresas aéreas segundo as regras verificadas.

3.8 Validação das diferenças de horário e das categorias de atraso

Para os voos realizados, foram calculadas as diferenças entre os horários reais e previstos de partida e chegada. Os resultados foram comparados com as categorias originais de situação registradas na base.

Nesta verificação, foi utilizada a base original, antes da remoção das duas cópias excedentes. Foram considerados 949.893 registros avaliáveis para cada cálculo de diferença de horário.

Indicador	Partida	Chegada
Atrasos calculados de 1 a 29 minutos	290.572	263.423
Atrasos positivos classificados como PONTUAL na fonte	294.311	266.816
Atrasos calculados de 30 minutos ou mais classificados como PONTUAL	3.739	3.393

A comparação identificou diferenças entre o cálculo direto dos horários e a classificação original. Esses resultados indicam que a classificação PONTUAL não corresponde necessariamente a uma diferença calculada igual a zero minuto.

As diferenças podem estar relacionadas a tolerâncias operacionais, arredondamentos ou critérios específicos utilizados pela fonte para definir pontualidade e intervalos de atraso. Essas possibilidades não foram confirmadas de forma independente.

Também foram identificadas divergências no limite de quatro horas: 11 partidas e 13 chegadas apresentaram diferenças calculadas de 241 minutos, embora estivessem classificadas pela fonte como `Atraso 120-240`.

Por esse motivo, os resultados não foram tratados automaticamente como erros. As regras de classificação e os limites exatos das faixas deverão ser confirmados antes de qualquer ajuste ou recategorização.

Conclusão

Os cálculos permitem identificar situações que merecem investigação e demonstram a importância de validar as regras de negócio antes de utilizar as categorias originais em indicadores de desempenho.

3.9 Registro consolidado dos achados

Os resultados das verificações foram organizados em um registro consolidado contendo a descrição de cada achado, a quantidade de ocorrências, o percentual correspondente à base e a ação recomendada.

Entre os principais pontos documentados estão:

- Ausências nas situações de partida e chegada.
- Ausências simultâneas dos horários previstos.
- Duas cópias excedentes de registros duplicados.
- Registros com zero assentos.
- Ausências no código de tipo de linha.
- Diferenças entre os atrasos calculados e as classificações originais.
- Diferenças nas descrições associadas a alguns códigos ICAO de aeroportos, ainda pendentes de validação.
- Necessidade de confirmar as regras de classificação de pontualidade e atraso.

As quantidades representam verificações distintas e podem se sobrepor. Portanto, não devem ser somadas para estimar o total de registros problemáticos.

3.10 Conclusão da etapa de qualidade

A avaliação de qualidade permitiu verificar a completude, a unicidade, a validade e a consistência dos principais campos utilizados no projeto.

Foram identificados pontos de atenção, mas também resultados favoráveis: não foram encontrados horários preenchidos inválidos, inversões cronológicas ou inconsistências nas associações entre códigos e nomes das empresas aéreas avaliadas.

Os achados foram documentados sem alteração da base original. Permanecem como pontos de investigação a validação das descrições de alguns aeroportos, a interpretação dos valores de zero assentos e a confirmação das regras utilizadas para classificar pontualidade e faixas de atraso.

A decisão sobre as duplicidades foi executada na etapa seguinte, após a documentação dos casos identificados.

Com essa etapa concluída, foi possível avançar para o tratamento inicial e a preparação dos dados, respeitando as limitações identificadas e evitando tratar como erros situações que ainda dependem de validação contextual.

Etapa 4 — Tratamento e preparação dos dados

Após a inspeção e a avaliação da qualidade dos dados, foi realizada a etapa inicial de tratamento e preparação da base operacional de voos de 2025.

O objetivo foi organizar os dados para as análises posteriores, corrigindo problemas identificados quando havia justificativa técnica e preservando informações que ainda dependem de investigação.

O tratamento foi realizado em uma cópia da base original, denominada **`df_tratado`.** Dessa forma, os dados originais foram mantidos em **`df`**, permitindo comparar os resultados antes e depois das transformações.

4.1 Conversão das colunas temporais

As seguintes variáveis foram convertidas do formato textual para o tipo temporal **`datetime64[ns]`** do pandas:

- Partida Prevista;
- Partida Real;
- Chegada Prevista;
- Chegada Real.

A conversão utilizou o formato esperado dia/mês/ano hora, com tratamento de erros por meio do parâmetro **`errors="coerce"`**. Em seguida, foram verificadas as possíveis falhas de conversão nos valores originalmente preenchidos.

Verificação	Resultado
Colunas temporais convertidas	4
Falhas de conversão em Partida Prevista	0
Falhas de conversão em Partida Real	0
Falhas de conversão em Chegada Prevista	0
Falhas de conversão em Chegada Real	0

Os resultados demonstraram que todos os horários originalmente preenchidos puderam ser convertidos sem falhas. Os valores ausentes foram preservados, sem preenchimento automático.

A conversão permite realizar cálculos de diferenças entre horários, comparações cronológicas e análises temporais de maneira apropriada.

4.2 Exclusão da coluna sem valores preenchidos

A coluna **`Justificativa`** apresentava ausência em 100% dos registros. Como não fornecia informações para as análises previstas, foi removida da base de trabalho.

A decisão foi baseada na ausência total de valores preenchidos e na falta de utilidade analítica dessa coluna para os objetivos atuais do projeto.

A coluna **`Codeshare`**, apesar de apresentar aproximadamente 55,71% de valores ausentes, foi mantida, pois a ausência parcial não constitui, por si só, justificativa suficiente para removê-la.

Resultado

A base passou de 21 para 20 colunas. A base original permaneceu inalterada.

4.3 Preservação dos valores ausentes

Após a conversão dos horários e a exclusão da coluna **`Justificativa`**, foi realizada uma nova verificação dos valores ausentes.

Variável	Registros ausentes após o tratamento
Partida Prevista	28.198
Chegada Prevista	28.198
Partida Real	27.716
Chegada Real	27.716

As quantidades permaneceram iguais às identificadas na etapa de qualidade. Isso demonstra que a conversão não introduziu novas ausências nos campos temporais.

Os horários previstos ausentes continuam concentrados nos mesmos 28.198 registros, enquanto os horários reais ausentes correspondem aos voos cancelados identificados anteriormente.

Não foram realizadas imputações, pois não há informações suficientes para determinar os horários que deveriam ocupar esses campos.

4.4 Tratamento de duplicidades exatas

A verificação realizada na etapa de qualidade identificou duas cópias excedentes de registros duplicados exatos. Os registros pertencem a dois pares referentes ao voo 8172 da Qatar Airways, na rota entre os aeroportos SBGR e SKBO, com ocorrências em 7 e 14 de dezembro de 2025.

Após a análise, foi aplicada a remoção de duplicidades exatas com o método **`drop_duplicates()`** do pandas, considerando todas as colunas da base de trabalho.

Indicador	Resultado
Registros antes do tratamento	1.005.807
Cópias excedentes identificadas	2
Registros após o tratamento	1.005.805
Registros removidos	2
Duplicidades exatas restantes	0

A remoção foi limitada às cópias excedentes dos registros integralmente idênticos. Os registros distintos, mesmo quando pertencentes à mesma empresa, voo e rota, foram preservados.

A base original permaneceu inalterada, e as modificações foram realizadas exclusivamente em **`df_tratado`.**

4.5 Validação após o tratamento

Após as transformações, foram realizadas verificações para confirmar a integridade estrutural da base e a consistência dos campos temporais.

Os resultados demonstraram que:

- A base tratada permaneceu com 20 colunas, após a remoção de **`Justificativa`**.
- Foram mantidos 1.005.805 registros após a remoção das duas cópias excedentes.
- As quatro colunas temporais permaneceram no tipo **`datetime64[ns]`**.
- As quantidades de horários ausentes permaneceram consistentes com os resultados da etapa de qualidade.
- Não foram identificadas duplicidades exatas remanescentes.
- Não foram encontrados voos classificados como realizados sem horário real de partida.
- Não foram encontrados voos classificados como realizados sem horário real de chegada.

Essas verificações confirmaram os resultados das transformações realizadas até o momento.

4.6 Tratamento dos demais pontos de atenção

Nem todos os achados da etapa de qualidade devem ser resolvidos por substituição ou exclusão de valores. Alguns exigem validação contextual antes da definição de uma regra de tratamento.

Tipos de linha ausentes

Foram identificados 463 registros sem classificação de tipo de linha na base original. Esses valores serão investigados para determinar se existe uma forma confiável de recuperar a informação.

Até que isso seja possível, os registros serão mantidos sem imputação.

Horários previstos ausentes

Os 28.198 registros sem partida e chegada previstas serão considerados nas análises que dependem da disponibilidade desses horários.

Registros sem horários previstos não podem ser utilizados em cálculos diretos de diferença entre horários previstos e realizados. Por isso, a quantidade de registros válidos poderá variar conforme o indicador calculado.

Número de assentos igual a zero

Foram identificados 46.700 registros com zero assentos na base original. Como duas cópias excedentes removidas também apresentavam esse valor, a quantidade na base tratada passa a ser 46.698.

Esses valores não serão substituídos automaticamente, pois sua interpretação depende do modelo de equipamento e das características da operação. A investigação por empresa aérea, modelo e tipo de linha poderá ajudar a determinar se há casos que necessitam de correção ou apenas de tratamento analítico específico.

Descrições de aeroportos

Foram encontradas diferenças textuais associadas aos códigos ICAO FNBJ, SDLO, SSOU e SEQU. A padronização será considerada somente após a validação das descrições corretas, evitando alterações baseadas em suposições.

Categorias de pontualidade e atraso

A comparação entre as diferenças de horários calculadas e as categorias originais identificou divergências que podem estar relacionadas às regras de classificação utilizadas pela fonte.

As categorias originais serão preservadas até que os critérios de classificação sejam confirmados.

Esses pontos não foram tratados automaticamente, pois qualquer alteração sem fundamentação poderia introduzir informações incorretas ou comprometer a interpretação dos resultados.

4.7 Situação da base após o tratamento inicial

Ao final das transformações executadas, a base apresenta as seguintes características:

Indicador	Resultado
Registros originais	1.005.807
Registros na base tratada	1.005.805
Variáveis na base tratada	20
Colunas temporais convertidas	4
Falhas de conversão temporal	0
Duplicidades exatas restantes	0
Imputações realizadas	0
Categorias originais alteradas	0

A base tratada está preparada para iniciar análises operacionais que utilizem os campos já validados. Entretanto, a investigação de todos os pontos de atenção permanece em aberto.

A ausência de imputações e de alterações automáticas nas categorias foi uma decisão deliberada para preservar a confiabilidade dos dados.

4.8 Conclusão da etapa de tratamento e preparação

A etapa inicial de tratamento foi concluída com a conversão das quatro colunas temporais, a exclusão da coluna **`Justificativa`**, que apresentava 100% de valores ausentes, a remoção de duas cópias excedentes de registros duplicados e a validação dos resultados.

As verificações realizadas não identificaram falhas de conversão, duplicidades exatas remanescentes ou problemas no preenchimento dos horários reais dos voos realizados.

A base original foi preservada, e as transformações foram aplicadas somente à cópia de trabalho. Os valores ausentes e as categorias originais foram mantidos quando não havia justificativa suficiente para alteração.

O tratamento deve ser considerado **parcialmente concluído**, pois alguns pontos ainda dependem de investigação contextual, especialmente os valores iguais a zero em número de assentos, os códigos de tipo de linha ausentes e as diferenças nas descrições dos aeroportos.

Com essas ressalvas documentadas, foi possível avançar para a análise exploratória operacional.

5. Análise Exploratória dos Dados

5.1. Objetivo e escopo da análise

Após a inspeção, o tratamento e a validação dos dados, a etapa de análise exploratória teve como objetivo investigar o comportamento operacional dos voos registrados pela Agência Nacional de Aviação Civil (ANAC) ao longo de 2025.

A análise foi estruturada para responder a diferentes questões: como o volume de voos realizados se distribuiu ao longo do ano; como os cancelamentos variaram entre meses, companhias aéreas, tipos de linha e rotas; como as classificações de pontualidade se comportaram entre partida e chegada; e quais ocorrências exigiam uma investigação mais detalhada das diferenças entre os horários previstos e realizados.

Para isso, foram utilizadas técnicas de análise descritiva, agregação de dados, validação de consistência e visualização interativa com Python, pandas e Plotly. Os resultados foram organizados em gráficos analíticos e em um dashboard executivo exportado para HTML.

A análise tem caráter descritivo. Seu propósito é identificar padrões, diferenças e ocorrências relevantes na base de 2025, sem atribuir causas operacionais que não possam ser comprovadas pelos dados disponíveis.

5.2. Preparação das bases de análise

A análise exploratória utilizou a base tratada e a base analítica produzidas nas etapas anteriores. Para organizar o processamento, foram criadas cópias de trabalho e uma base específica para os voos realizados, preservando as bases originais.

Após o tratamento e a remoção das duplicatas exatas, a base utilizada na análise continha **1.005.805 registros e 20 colunas**. A base analítica, com colunas auxiliares destinadas às análises posteriores, possuía 1.005.805 registros e 27 colunas.

A distribuição dos registros por situação foi:

Situação do voo	Registros	Participação

Realizado	978.089	97,24%
Cancelado	27.716	2,76%
Total	**1.005.805**	**100,00%**

A preparação também padronizou as categorias utilizadas nas análises e conferiu a disponibilidade das colunas temporais necessárias.

Foram adotados critérios específicos conforme a pergunta investigada:

- **Volume mensal de voos realizados:** utilização do mês da partida real.
- **Taxa mensal de cancelamento:** utilização do mês da partida prevista, considerando registros com situação identificada como realizada ou cancelada.
- **Classificação de pontualidade:** análise dos campos de classificação de partida e chegada, com tratamento explícito dos registros sem classificação.
- **Diferenças entre horários:** cálculo das diferenças em minutos entre os horários reais e previstos disponíveis.
- **Ocorrências extremas:** identificação e investigação de registros com diferenças superiores a 24 horas, sem remoção automática.

Esses critérios evitam que indicadores com denominadores diferentes sejam interpretados como equivalentes. Também permitem manter os registros na base analítica quando sua ausência de informação impede apenas uma análise específica.

5.3. Volume mensal de voos realizados

Objetivo

Analisar a distribuição mensal dos voos realizados em 2025, identificando os meses com maior e menor volume de operações e observando as variações ao longo do período.

Metodologia

Foram considerados os registros classificados como realizados. O mês de referência foi extraído da coluna `Partida Real`, e os registros foram agrupados e contabilizados com pandas.

Essa escolha permite analisar as operações efetivamente registradas, em vez de atribuir os voos ao mês originalmente programado.

Resultados

Mês	Voos realizados

Janeiro	86.360
Fevereiro	76.172
Março	80.085
Abril	78.309
Maio	80.612
Junho	78.812
Julho	85.423
Agosto	82.802
Setembro	80.302
Outubro	83.666
Novembro	80.398
Dezembro	85.148
Total	**978.089**

A distribuição mostra que o volume de voos realizados não foi uniforme ao longo de 2025. Janeiro apresentou o maior número de registros, seguido por julho e dezembro, enquanto fevereiro concentrou o menor volume.

Essas diferenças identificam períodos com maior e menor movimentação na base analisada. Entretanto, os números, isoladamente, não permitem atribuir as variações à sazonalidade turística, às condições meteorológicas, à demanda ou a outros fatores externos.

A análise do volume mensal fornece o contexto necessário para interpretar os cancelamentos: a quantidade absoluta de ocorrências deve ser considerada em conjunto com o total de operações programadas.

5.4. Análise dos cancelamentos e dashboard executivo

Objetivo

Investigar a distribuição dos cancelamentos ao longo de 2025 e comparar sua ocorrência entre meses, tipos de linha, companhias aéreas e rotas. O objetivo é distinguir situações com grande volume absoluto de operações daquelas com maior proporção de cancelamentos.

5.4.1. Metodologia de cálculo da taxa de cancelamento

A taxa de cancelamento foi calculada pela seguinte relação:

Taxa de cancelamento (%) = (voos cancelados ÷ total de voos programados elegíveis) × 100

O total programado corresponde à soma dos registros realizados e cancelados que atendem aos critérios da análise.

Para atribuir cada registro ao mês correspondente, foi utilizada a coluna **`Partida Prevista`**. Os registros sem partida prevista não foram atribuídos artificialmente a um mês e ficaram fora desse cálculo específico, embora tenham sido mantidos na base analítica.

Dos 1.005.805 registros da base, **977.607 atenderam aos critérios de elegibilidade para o cálculo mensal**, incluindo os 27.716 cancelamentos. Os demais 28.198 registros não participaram do cálculo por ausência de partida prevista.

5.4.2. Evolução mensal dos cancelamentos

A análise mensal identificou diferenças relevantes entre os períodos do ano.

- **Maior quantidade de cancelamentos:** dezembro, com 3.424 registros.
- **Segundo maior volume:** janeiro, com 3.244 cancelamentos.
- **Menor quantidade:** agosto, com 1.799 cancelamentos.
- **Maior taxa mensal:** dezembro, com 4,01%.
- **Menor taxa mensal:** agosto, com 2,17%.

A diferença entre a maior e a menor taxa mensal foi de 1,84 ponto percentual.

Interpretação

Dezembro apresentou a maior incidência relativa de cancelamentos, enquanto agosto registrou a menor. Janeiro também apresentou um volume elevado de ocorrências.

A combinação entre quantidade absoluta e taxa de cancelamento é importante porque os indicadores respondem a perguntas diferentes. A quantidade mostra o número de ocorrências; a taxa relaciona essas ocorrências ao volume programado elegível.

Os resultados demonstram que os cancelamentos variaram ao longo do ano. Entretanto, não permitem atribuir essa variação a feriados, férias, demanda, condições meteorológicas ou outros fatores sem informações adicionais.

5.4.3. Distribuição por tipo de linha

A distribuição dos registros por tipo de linha foi:

Tipo de linha	Realizados	Cancelados	Total

Nacional	790.794	14.067	804.861
Internacional	157.096	6.700	163.796
Geral	16.651	4.785	21.436
Cargueiro	13.548	1.701	15.249
Não classificado	0	463	463
Total	**978.089**	**27.716**	**1.005.805**

As operações nacionais representaram aproximadamente 80,0% da base, enquanto as internacionais corresponderam a cerca de 16,3%. As categorias geral e cargueira apresentaram volumes menores.

A categoria nacional concentrou a maior quantidade absoluta de voos realizados e cancelados, o que deve ser interpretado considerando seu volume operacional superior.

Para comparar a participação dos cancelamentos entre categorias, foram calculadas as seguintes taxas sobre o total de registros de cada tipo de linha:

Tipo de linha	Taxa de cancelamento
Nacional	1,75%
Internacional	4,09%
Geral	22,33%
Cargueiro	11,16%

A categoria geral apresentou a maior taxa, seguida pela cargueira, pela internacional e pela nacional.

As taxas não demonstram, isoladamente, diferenças de eficiência operacional, pois o perfil das operações e a composição de cada categoria podem influenciar os resultados.

5.4.4. Volume operacional por companhia aérea

A análise de volume identificou concentração das operações em poucas companhias.

Companhia aérea	Realizados	Cancelados	Total
Azul Linhas Aéreas	294.573	4.933	299.506
TAM Linhas Aéreas	286.577	4.711	291.288

GOL Linhas Aéreas	245.549	2.818	248.367
Azul Conecta	15.694	2.228	17.922
LATAM Airlines Group (LAN)	12.051	75	12.126
TAP	10.125	141	10.266

A Azul apresentou o maior volume, com 299.506 registros, seguida pela TAM, com 291.288, e pela GOL, com 248.367. Juntas, essas três empresas concentraram aproximadamente 83,4% da base.

Esse resultado demonstra a importância de considerar o volume de operações ao comparar quantidades de cancelamentos. Uma companhia com maior quantidade de ocorrências também pode possuir uma base operacional muito maior.

Por isso, a análise de volume foi complementada por indicadores relativos de cancelamento.

5.4.5. Companhias com maiores taxas de cancelamento

Foram consideradas companhias com pelo menos 1.000 voos programados elegíveis. A seleção reduz a influência de grupos com poucas observações, embora não elimine todas as diferenças entre os perfis operacionais.

Entre as companhias analisadas, a Arajet S.A. apresentou a maior taxa anual de cancelamento, com 59,47%, seguida pela Ethiopian Airlines Group, com 52,77%, e pela Iberia, com 36,80%. As demais companhias entre as dez maiores taxas apresentaram percentuais entre 15,14% e 29,38%.

Os resultados foram utilizados para selecionar grupos que mereciam uma análise temporal mais detalhada. A taxa anual, entretanto, não representa necessariamente o comportamento da companhia em todos os meses.

5.4.6. Evolução mensal das taxas por companhia

A análise mensal revelou padrões distintos entre as empresas selecionadas.

A Arajet apresentou taxas nulas em janeiro e fevereiro e de 9,68% em março. A partir de abril, os percentuais ultrapassaram 50%, chegando a 73,86% em outubro.

A Ethiopian Airlines manteve taxas relativamente estáveis entre janeiro e outubro, variando de 52,98% a 55,33%. Em novembro e dezembro, os percentuais foram menores, de acordo com os resultados registrados na base.

A Iberia apresentou taxas inferiores a 8% entre janeiro e março. A partir de abril, os percentuais aumentaram, atingindo 57,89% em novembro e 54,05% em dezembro.

Outros resultados relevantes foram a taxa de 55,74% da ABSA em dezembro e de 58,62% da Total Linhas Aéreas em junho.

Esses padrões demonstram que a taxa anual pode ocultar diferenças importantes entre períodos. A evolução mensal permite localizar quando os percentuais aumentaram ou diminuíram e orientar investigações mais específicas.

5.4.7. Investigação das taxas por rota

A análise foi aprofundada por rota para verificar se as taxas elevadas de determinadas companhias também apareciam em combinações específicas de origem e destino.

Foram consideradas rotas com pelo menos 30 voos programados elegíveis. Entre os resultados, seis combinações apresentaram 100% de cancelamento na base analisada:

- MDPC–SAEZ e SAEZ–MDPC, associadas à Arajet;
- EBLG–SBGR, SBGR–EBLG, SBGR–GOBD e SBGR–LEZG, associadas à Ethiopian Airlines.

Nas duas rotas da Arajet, foram contabilizados 401 e 413 voos programados elegíveis, respectivamente, todos classificados como cancelados.

Também foram observadas taxas de 94,68% na rota SBGR–SCEL, com 676 cancelamentos em 714 registros elegíveis, e de 92,11% na rota DNMM–SBGR, com 771 cancelamentos em 837 registros elegíveis.

A análise das rotas permitiu distinguir ocorrências concentradas em combinações específicas de origem e destino de padrões mais amplos observados no nível das companhias.

As taxas elevadas foram verificadas ao longo de vários meses nas rotas selecionadas, o que justificou examinar a distribuição por número de voo, tipo de linha, data e disponibilidade de partida prevista.

Esses resultados descrevem a base elegível de 2025. Não comprovam, isoladamente, que todos os voos previstos nessas rotas deixaram de operar em sentido operacional mais amplo, nem identificam as causas dos cancelamentos. A interpretação depende da cobertura e da consistência dos registros disponíveis.

5.4.8. Dashboard executivo

Os indicadores e resultados foram reunidos em um dashboard interativo desenvolvido com Python, Plotly e HTML.

O dashboard foi organizado em painéis e abas para separar as diferentes perspectivas da análise, permitindo alternar entre as visualizações sem concentrar todos os gráficos em uma única página.

O dashboard integrado possui três abas principais: Visão geral, Cancelamentos e Pontualidade e atrasos. Dentro dos painéis, subabas organizam as visualizações por tipo de linha, volume, taxas de cancelamento, evolução mensal, classificações de pontualidade, rankings de atrasos e mapa de rotas.

A visão geral apresenta os indicadores de voos realizados e cancelados de acordo com os meses de 2025, volume de voos de acordo com o tipo de linha e também por empresas. Já no painel de cancelamentos eu exploro as rotas com maiores cancelamentos, as empresas e a evolução mensal da taxa de cancelamento usando um heatmap para as companhias que mais pontuaram nesse aspecto. Por fim, o painel de pontualidade e atrasos reúne a comparação das classificações de partida e chegada, a variação entre horários antecipados, pontuais e atrasados usando fluxo Sankey, os rankings por grupo operacional e o mapa das rotas com maiores atrasos.

A principal contribuição do dashboard é transformar os resultados em um recurso de consulta que facilita a exploração dos padrões, a análise dos dados e tomada de decisão com base em valores concretos.

5.5. Análise da pontualidade operacional

Objetivo

Investigar as classificações de pontualidade registradas pela ANAC, comparando partidas e chegadas e observando a distribuição temporal e operacional das categorias.

Para facilitar algumas comparações, as faixas de atraso foram agrupadas em uma categoria analítica denominada **Atrasado**, preservando a distinção entre antecipação, pontualidade e ausência de classificação.

O agrupamento foi utilizado para visualização e comparação. Ele não substitui as categorias originais nem permite avaliar, por si só, a duração dos atrasos.

5.5.1. Distribuição das classificações de partida e chegada

Entre os voos realizados, foram registrados:

Classificação	Partida	Chegada
Antecipado	516.430	578.364
Pontual	349.759	290.161
Atraso de 30 a 60 min	47.558	46.008
Atraso de 60 a 120 min	21.962	21.586
Atraso de 120 a 240 min	9.420	9.089

Atraso superior a 240 min	4.762	4.683
Sem classificação	28.198	28.198
Total	**978.089**	**978.089**

Os percentuais calculados sobre todos os voos realizados incluem os registros sem classificação. Quando a análise considera apenas os 949.891 registros classificados, os percentuais passam a utilizar esse conjunto como denominador.

Entre os registros classificados, 54,37% das partidas e 60,89% das chegadas foram classificadas como antecipadas. As partidas pontuais corresponderam a 36,82% dos registros classificados, enquanto as chegadas pontuais representaram 30,55%.

As categorias de atraso apresentam diferentes faixas de duração. Por esse motivo, a participação agregada de voos atrasados deve ser interpretada em conjunto com a análise específica das diferenças de horário.

5.5.2. Evolução mensal das classificações

A evolução mensal foi construída utilizando o mês da partida real dos voos realizados. As classificações foram agrupadas em Antecipado, Pontual, Atrasado e Sem classificação.

A categoria Pontual permaneceu predominante na visualização ao longo do período analisado. As participações relativas de Antecipado e Atrasado oscilaram entre os meses, sem evidência visual de crescimento ou redução contínua da participação dos atrasos durante todo o ano.

A análise temporal complementa a distribuição agregada, pois permite identificar períodos em que a composição das classificações mudou.

Os percentuais mensais incluem registros sem classificação no denominador. Portanto, não devem ser comparados diretamente aos percentuais calculados exclusivamente sobre os registros classificados.

5.5.3. Ranking de atrasos por grupo operacional

Para comparar a frequência relativa de atrasos entre companhias aéreas, rotas e aeroportos de origem, as categorias de atraso foram agrupadas em uma única categoria denominada Atrasado.

Foram utilizados registros com classificação de partida preenchida. Os percentuais foram calculados em relação ao total de partidas classificadas de cada grupo.

Para reduzir a influência de amostras muito pequenas, foram adotados os seguintes volumes mínimos:

- 1.000 partidas classificadas para companhias aéreas;
- 500 partidas classificadas para rotas;

- 1.000 partidas classificadas para aeroportos de origem.

Esses limites são critérios analíticos de seleção, não indicadores oficiais de qualidade operacional.

Entre as companhias selecionadas, a Atlas Air apresentou o maior percentual de partidas classificadas como atrasadas, com 74,38%. Em seguida, apareceram a LAN Cargo, com 64,65%, a TAMPA Cargo, com 55,18%, e a ABSA, com 52,10%.

O ranking evidencia diferenças relevantes entre os grupos selecionados. Entretanto, como a categoria Atrasado reúne faixas de duração distintas, o percentual representa a frequência relativa de atrasos, e não sua gravidade. Os resultados também não identificam as causas das diferenças observadas.

5.5.4. Fluxo entre as classificações de partida e chegada

A análise de fluxo foi desenvolvida para investigar como as classificações de partida se relacionam com as classificações de chegada.

O diagrama Sankey apresenta as categorias de partida de um lado e as categorias de chegada do outro. A espessura das conexões representa a quantidade de voos que percorreu cada combinação de classificações.

Essa visualização complementa os gráficos de distribuição porque não mostra apenas quantos registros pertencem a cada categoria: ela também permite observar a correspondência entre as classificações nas duas etapas da operação.

O diagrama deve ser interpretado como uma representação das transições registradas na base. Ele não demonstra, isoladamente, que um atraso na partida causou determinada classificação na chegada, nem permite avaliar a duração do atraso sem consultar as diferenças de horário.

5.5.5. Mapa das rotas com maior percentual de partidas atrasadas

O mapa foi desenvolvido para representar geograficamente as rotas que apresentaram os maiores percentuais de partidas classificadas como atrasadas.

Foram considerados voos realizados com origem e destino identificados por códigos ICAO distintos. O percentual de atraso foi calculado pela relação entre partidas classificadas como atrasadas e o total de partidas classificadas de cada rota.

Para reduzir a influência de amostras pequenas, foram consideradas rotas com pelo menos 30 partidas classificadas. Após a validação dos dados geográficos, foram selecionadas as 20 rotas com maiores percentuais para a visualização.

O resultado final apresentou percentuais entre 57,4% e 90,2% nas rotas exibidas. A cor das conexões representa o percentual de atraso, permitindo comparar visualmente a frequência relativa entre os trajetos.

O mapa ajuda a identificar concentrações geográficas de rotas com percentuais elevados e a orientar investigações posteriores. Entretanto, representa apenas as rotas selecionadas pelos critérios definidos. Não deve ser interpretado como um mapa completo da operação aérea brasileira nem como evidência de que a localização geográfica seja a causa dos atrasos.

5.6. Diferenças entre horários previstos e realizados

Objetivo

Complementar a análise baseada nas classificações da ANAC por meio do cálculo direto das diferenças, em minutos, entre os horários previstos e reais de partida e chegada.

Essa análise permite distinguir antecipações, horários iguais aos previstos e atrasos, além de investigar a distribuição das diferenças, os atrasos prolongados e os registros extremos.

5.6.1. Base de cálculo e critérios

A análise foi realizada sobre os 978.089 voos classificados como realizados. Desse total, 949.891 registros (97,12%) apresentaram os horários previstos e reais necessários para calcular as diferenças. Os outros 28.198 registros (2,88%) não possuíam os horários previstos necessários para essas comparações.

As diferenças foram interpretadas da seguinte forma:

- **Diferença negativa:** o horário real ocorreu antes do previsto.
- **Diferença igual a zero:** o horário real coincidiu com o previsto.
- **Diferença positiva:** o horário real ocorreu depois do previsto.

Os registros sem informações suficientes não foram considerados nas estatísticas de diferenças calculáveis. Entretanto, foram mantidos na base.

5.6.2. Distribuição das diferenças de horário

Na partida, foram identificadas 516.430 antecipações, 55.448 partidas no horário previsto e 378.013 partidas com atraso.

Na chegada, foram identificadas 578.364 antecipações, 23.345 chegadas no horário previsto e 348.182 chegadas com atraso.

Classificação calculada	Partida	Chegada
Antecipação	54,37%	60,89%
Horário igual ao previsto	5,84%	2,46%
Atraso	39,80%	36,65%

Registros avaliáveis	**949.891**	**949.891**

As antecipações foram mais frequentes que os atrasos tanto na partida quanto na chegada. A proporção de atrasos calculados foi aproximadamente 3,15 pontos percentuais maior na partida.

Esses percentuais descrevem as diferenças calculadas entre os horários disponíveis. Não devem ser tratados automaticamente como um indicador oficial de pontualidade, pois a classificação e os critérios utilizados podem diferir dos critérios operacionais específicos da ANAC.

5.6.3. Estatísticas descritivas das diferenças

As estatísticas descritivas apresentaram os seguintes resultados:

Estatística	Diferença de partida	Diferença de chegada
Média	7,62 min	3,58 min
Desvio-padrão	78,72 min	79,62 min
Mediana	-2 min	-5 min
Primeiro quartil (25%)	-7 min	-13 min
Terceiro quartil (75%)	8 min	7 min
Menor diferença	-2.890 min	-2.984 min
Maior diferença	44.635 min	44.625 min

As médias positivas indicam que, considerando todos os registros com diferenças calculáveis, o saldo médio foi de 7,62 minutos após o horário previsto na partida e de 3,58 minutos na chegada.

As medianas, por outro lado, foram negativas: -2 minutos na partida e -5 minutos na chegada. Isso mostra que o registro central da distribuição ocorreu antes do horário previsto.

A diferença entre média e mediana é relevante porque a média é sensível a valores extremos. Os quartis também mostram que 50% das diferenças observadas ficaram entre -7 e 8 minutos na partida e entre -13 e 7 minutos na chegada.

Portanto, as médias positivas não representam, isoladamente, o comportamento típico de todos os voos. A interpretação exige considerar a distribuição completa e a presença de ocorrências extremas.

5.6.4. Atrasos acima de limites de tempo

Foram investigadas diferenças positivas superiores a 60, 120, 240, 720, 1.440 e 2.880 minutos.

Limite de atraso	Partidas	Chegadas
Superior a 60 min	36.220 (3,81%)	35.439 (3,73%)
Superior a 120 min	14.211 (1,50%)	13.814 (1,45%)
Superior a 240 min	4.773 (0,50%)	4.696 (0,49%)
Superior a 720 min	1.046 (0,11%)	1.026 (0,11%)
Superior a 1.440 min	269 (0,03%)	276 (0,03%)
Superior a 2.880 min	34 (0,00%)	35 (0,00%)

Os percentuais foram calculados sobre os 949.891 registros avaliáveis de cada etapa.

Os atrasos superiores a quatro horas corresponderam a aproximadamente 0,50% das diferenças de partida e 0,49% das diferenças de chegada. Embora representem uma parcela pequena dos registros avaliáveis, essas ocorrências são relevantes para a investigação de casos específicos.

A análise cumulativa também mostra que a quantidade de ocorrências diminui à medida que o limite de tempo aumenta.

5.6.5. Investigação de diferenças extremas

Foi adotado o limite de 1.440 minutos (24 horas) para identificar diferenças extremas. O objetivo não foi excluir automaticamente esses registros, mas identificar ocorrências que merecessem verificação adicional.

Foram encontrados:

- 307 registros com diferenças extremas na partida;
- 345 registros com diferenças extremas na chegada;
- 363 registros com diferenças extremas em pelo menos uma das duas etapas.

Entre as partidas extremas, 269 apresentaram diferenças superiores a 24 horas após o horário previsto e 38 apresentaram diferenças superiores a 24 horas antes do previsto. Nas chegadas, foram identificadas 276 diferenças superiores a 24 horas após o horário previsto e 69 anteriores ao previsto.

O maior caso identificado apresentou diferença de 44.635 minutos na partida, equivalente a aproximadamente 31 dias. A diferença de chegada no mesmo registro foi de 44.625 minutos.

Também foram observadas diferenças de vários dias em registros de operações de carga, envolvendo companhias como TAMPA Cargo, LANCO e Atlas Air.

Essas ocorrências demonstram a importância de examinar valores extremos antes de interpretar médias e desvios-padrão. Entretanto, os dados disponíveis não confirmam que todos os casos sejam erros de registro. Cada ocorrência exigiria a verificação da programação original, das datas e das informações operacionais correspondentes.

5.6.6. Comparação com as classificações da ANAC

As diferenças calculadas foram comparadas às classificações registradas nos campos de situação de partida e chegada, com atenção especial ao limite de 240 minutos.

Na partida, foram identificados 4.773 registros com diferenças calculadas superiores a 240 minutos, enquanto 4.762 estavam classificados como “Atraso > 240”. A comparação identificou 11 divergências.

Na chegada, foram identificadas 4.696 diferenças superiores a 240 minutos, enquanto 4.683 registros estavam classificados como “Atraso > 240”, resultando em 13 divergências.

Todos os registros divergentes apresentados possuíam diferença calculada de 241 minutos, mas estavam classificados como “Atraso 120-240”. Não foram encontrados registros classificados pela ANAC como “Atraso > 240” cuja diferença calculada fosse igual ou inferior a 240 minutos.

A concentração das divergências no limite de 241 minutos indica uma questão localizada na transição entre as faixas de atraso. Contudo, os resultados não permitem concluir se a diferença decorre de uma regra de classificação, arredondamento ou outro critério operacional.

A comparação demonstra a utilidade de validar classificações fornecidas pela fonte com cálculos independentes, sem presumir antecipadamente que uma das representações esteja incorreta.

5.6.7. Distribuição das ocorrências extremas por empresa e rota

A Atlas Air apresentou a maior quantidade de registros extremos, com 148 ocorrências, seguida pela American Airlines, com 71, e pela GOL, com 20.

A Atlas Air correspondeu a aproximadamente 40,8% dos 363 registros extremos identificados, enquanto a American Airlines representou cerca de 19,6%.

Na análise por rota, KMIA–SBGL apresentou 60 ocorrências extremas, seguida por SBGR–SCEL, com 23, e KMIA–SBKP e KMIA–SBEG, com 19 cada.

Esses valores são contagens absolutas. Como não foram normalizados pelo volume total de voos de cada empresa ou rota, não permitem concluir que os grupos tenham maior probabilidade de apresentar ocorrências extremas.

A distribuição pode orientar uma investigação posterior, desde que seja complementada por denominadores comparáveis e pela verificação individual dos registros.

5.6.8. Relação entre diferenças extremas de partida e chegada

Entre os 363 registros extremos, 289 apresentaram diferenças extremas tanto na partida quanto na chegada. Outros 56 tiveram ocorrência extrema apenas na chegada e 18 apenas na partida.

A variação entre as diferenças de partida e chegada apresentou média de -9,64 minutos e mediana de -5 minutos. Em 268 registros, equivalentes a 73,83% dos casos extremos avaliáveis, a variação absoluta entre as duas diferenças foi de até 30 minutos.

Esse resultado indica que, em boa parte dos casos extremos, o desvio em relação ao horário previsto foi semelhante na partida e na chegada.

Entretanto, essa relação não comprova a causa do desvio. Para determinar se as ocorrências representam atrasos efetivos, alterações de programação ou inconsistências temporais, seria necessária uma investigação individual com informações operacionais complementares.

5.7. Síntese e validação final dos resultados

A validação final confirmou que a base tratada possuía 1.005.805 registros e 20 colunas, sem duplicatas exatas. A base analítica manteve os mesmos 1.005.805 registros, com 27 colunas.

A distribuição por situação permaneceu consistente: 978.089 voos realizados e 27.716 cancelados. A soma dos registros por situação correspondeu ao total da base.

Também foram verificadas as quantidades utilizadas nas análises temporais. Todos os 978.089 voos realizados foram contabilizados no volume mensal pela data de partida real. Para o cálculo da taxa de cancelamento, 977.607 registros atenderam aos critérios de elegibilidade; os 28.198 registros sem partida prevista permaneceram na base, mas não foram atribuídos artificialmente a um mês programado.

A validação das diferenças de horário confirmou 949.891 registros avaliáveis para partida e chegada, além das contagens de antecipações, horários iguais, atrasos e registros ausentes. As divergências identificadas em torno do limite de 240 minutos foram mantidas como ocorrências para investigação, não como erros automaticamente confirmados.

Principais resultados da etapa

A análise exploratória permitiu identificar cinco resultados centrais:

1. **Variação no volume de operações:** janeiro apresentou o maior volume mensal de voos realizados, enquanto fevereiro registrou o menor.

2. **Variação temporal dos cancelamentos:** dezembro apresentou a maior taxa mensal, com 4,01%, enquanto agosto registrou a menor, com 2,17%.
3. **Diferenças entre grupos operacionais:** as taxas de cancelamento variaram por tipo de linha, companhia aérea e rota, permitindo identificar grupos prioritários para investigação.
4. **Diferenças entre classificações e horários:** as antecipações foram mais frequentes que os atrasos entre os registros avaliáveis, enquanto as estatísticas descritivas demonstraram a influência de ocorrências extremas sobre as médias.
5. **Necessidade de validação dos casos extremos:** foram identificados 363 registros com diferenças superiores a 24 horas em pelo menos uma etapa, além de 11 divergências de classificação na partida e 13 na chegada em relação ao limite de 240 minutos.

Limitações da análise

Os resultados representam os registros disponíveis na base VRA de 2025 e dependem da qualidade, da cobertura e da consistência dessas informações.

A ausência de horários previstos impede o cálculo de determinadas diferenças e a inclusão de registros em algumas taxas mensais. Os rankings também utilizam critérios mínimos de volume, o que restringe os grupos apresentados e não elimina todas as diferenças entre seus perfis operacionais.

Além disso, as análises são descritivas. Elas identificam associações, variações e ocorrências relevantes, mas não demonstram relações causais. A investigação das causas dos cancelamentos e dos atrasos exigiria dados complementares sobre condições meteorológicas, restrições operacionais, programação das companhias e outros fatores.

Conclusão

A análise exploratória transformou a base tratada em um conjunto de indicadores e visualizações capazes de descrever o volume operacional, a distribuição dos cancelamentos, as classificações de pontualidade e as diferenças entre horários previstos e realizados.

A combinação entre análise temporal, comparação por grupos operacionais, visualizações interativas e validação de consistência permitiu ir além da apresentação de totais. Foi possível identificar períodos e grupos que merecem investigação, diferenciar quantidades absolutas de taxas e examinar ocorrências extremas sem removê-las automaticamente.

O dashboard executivo complementa a análise ao reunir os principais indicadores em uma interface navegável, facilitando a exploração dos resultados.

Assim, a etapa de análise dos dados conclui o processo exploratório do projeto e estabelece uma base analítica para futuras investigações mais específicas sobre os fatores associados aos cancelamentos e atrasos na aviação brasileira.

6. Conclusões e principais insights

6.1. Síntese do projeto

Este projeto teve como objetivo investigar aspectos operacionais da aviação comercial brasileira ao longo de 2025, utilizando dados públicos da Agência Nacional de Aviação Civil (ANAC) e recursos de análise de dados em Python.

O trabalho envolveu o carregamento e a consolidação dos arquivos mensais, a inspeção da qualidade dos dados, o tratamento de inconsistências, a construção de uma base analítica e o desenvolvimento de análises exploratórias e visualizações interativas.

Após o tratamento, a base analítica reuniu 1.005.805 registros, dos quais 978.089 foram classificados como voos realizados e 27.716 como cancelados. Esses dados permitiram investigar padrões relacionados ao volume de operações, aos cancelamentos, às companhias aéreas, aos tipos de linha e ao comportamento dos atrasos.

6.2. Principais insights

Volume operacional

A análise mensal dos voos realizados evidenciou variações no volume de operações ao longo do ano. Janeiro apresentou o maior volume, com 86.360 voos realizados, enquanto fevereiro registrou o menor, com 76.172.

Essas diferenças descrevem a distribuição temporal das operações, mas, isoladamente, não permitem determinar quais fatores explicam as variações observadas.

Cancelamentos

Os cancelamentos foram investigados sob diferentes perspectivas, incluindo a evolução mensal, os tipos de linha, as companhias aéreas e as combinações entre empresas e rotas.

A análise por tipo de linha identificou diferenças nas taxas de cancelamento: 1,75% para voos nacionais, 4,09% para internacionais, 11,16% para carga e 22,33% para aviação geral, considerando as categorias classificadas na base.

Esses resultados indicam que o comportamento dos cancelamentos varia entre os segmentos analisados. As comparações devem considerar, entretanto, o volume de operações de cada categoria e as características dos registros disponíveis.

Pontualidade e atrasos

Entre os voos realizados com diferenças de horário calculáveis, foram identificados 949.891 registros avaliáveis.

Na partida, 54,37% apresentaram antecipação em relação ao horário previsto, 5,84% ocorreram no horário previsto e 39,80% apresentaram atraso. Na chegada, 60,89% foram antecipados, 2,46% ocorreram no horário previsto e 36,65% apresentaram atraso.

A análise também demonstrou a importância de diferenciar a distribuição dos atrasos por faixa de duração das medidas de tendência central. Embora as diferenças médias tenham sido positivas, os valores extremos influenciam essas médias; por isso, a mediana também é relevante para compreender o comportamento mais típico das operações.

Qualidade e consistência dos dados

A avaliação da qualidade dos dados foi parte importante do projeto. Foram identificadas e tratadas duas cópias excedentes de registros duplicados, além de valores ausentes e diferenças entre algumas classificações de atraso e os cálculos realizados a partir dos horários.

Essas verificações reforçam que a análise operacional não depende apenas da criação de gráficos, mas também da compreensão das regras de classificação, da consistência dos registros e dos limites de interpretação das informações disponíveis.

6.3. Principais descobertas do projeto

Ao longo da análise, cinco resultados se destacaram:

- Janeiro apresentou o maior volume operacional do ano, enquanto fevereiro registrou o menor volume de voos realizados.
- A taxa de cancelamento variou ao longo de 2025, atingindo seu maior valor em dezembro (4,01%) e o menor em agosto (2,17%).
- As taxas de cancelamento diferiram significativamente entre tipos de linha, companhias aéreas e rotas, indicando comportamentos operacionais heterogêneos.
- As antecipações foram mais frequentes que os atrasos tanto na partida quanto na chegada dos voos avaliáveis.
- Foram identificados registros extremos com diferenças superiores a 24 horas, reforçando a importância da validação da qualidade dos dados antes da interpretação das métricas.

6.4. Possibilidades de continuidade

Como evolução do projeto, análises futuras poderiam ampliar a comparação temporal, investigar a estabilidade dos padrões observados entre anos, aprofundar o comportamento de rotas específicas e avaliar os indicadores considerando o volume operacional de cada grupo.

Também seria possível desenvolver análises complementares sobre a concentração dos cancelamentos, a recorrência de atrasos em determinados trechos e a sensibilidade dos resultados às regras de classificação adotadas.

Essas possibilidades representam extensões da investigação e não conclusões já estabelecidas pelos resultados atuais.

6.5. Considerações finais

O projeto demonstra a aplicação de Python à análise de dados operacionais reais, combinando preparação de dados, validação de qualidade, análise exploratória, cálculo de indicadores e visualização interativa.

Mais do que apresentar métricas isoladas, o trabalho busca construir uma investigação rastreável, na qual as decisões de tratamento, os critérios de cálculo e as limitações dos dados sejam considerados na interpretação dos resultados.

Dessa forma, o projeto consolida uma aplicação prática de análise de dados voltada à compreensão de padrões operacionais da aviação brasileira e à comunicação dos resultados por meio de evidências quantitativas.